Predicción de demanda de Ecobici CDMX: segundo reporte de avance

Fernando Barba, Jose Luis Santiago, Tania Hernández

Minería y Análisis de Datos

1. Problema y objetivo

Ecobici opera 677 estaciones registradas en su catálogo y el rebalanceo de bicicletas requiere anticipar dónde y cuándo harán falta. Actualmente, el restock suele ser reactivo: se reponen bicicletas cuando una estación ya tiene pocas o se queda sin ellas. Este proyecto busca predecir cuántas bicicletas saldrán de cada estación en cada hora, para planear con una semana de anticipación el movimiento de bicicletas desde estaciones donde sobran hacia aquellas donde se necesitan.

Se plantea como un problema de aprendizaje supervisado de regresión. La variable objetivo es el número de salidas por estación y hora: una cantidad numérica de conteo, no una categoría. El modelo aprende a partir de viajes anteriores y utiliza información de calendario, ubicación y comportamiento reciente de cada estación.

Objetivos específicos:

- Cuantificar las salidas de bicicletas por estación, fecha y hora.
- Anticipar qué estaciones necesitarán reposición y en qué horarios.
- Modelar cómo cambia la demanda según la hora, el tipo de día, la ubicación y el comportamiento de las semanas anteriores.

2. Datos

Se utilizan dos fuentes. La primera es el portal de datos abiertos de Ecobici, que publica archivos CSV mensuales en los que cada registro corresponde a un viaje. La segunda es el feed GBFS (General Bikeshare Feed Specification), del que se obtiene el catálogo de estaciones con su ubicación y capacidad.

Dato	Cantidad o periodo
Viajes analizados	9.3 millones
Periodo principal	Marzo a agosto de 2026
Estaciones del catálogo	677
Viajes conservados después del filtro de duración	98.2 %
Filas para el modelo	2,842,368 (estación × fecha × hora)
Datos para experimentos con más historia	20.3 millones de viajes, septiembre de 2025 a septiembre de 2026

Los archivos originales están en formato CSV mensual y cada fila representa un viaje. Para el modelo, los viajes se agrupan por estación, fecha y hora, de modo que la observación deja de ser un viaje individual y pasa a representar la demanda de una estación durante una hora.

3. Limpieza de datos

Antes de construir el modelo se tomaron cuatro decisiones de limpieza. Se conservaron los registros cuyo comportamiento es compatible con las reglas de operación del servicio y se corrigió la forma de identificar las estaciones para evitar asignaciones equivocadas.

Problema	Decisión	Justificación
Duración del viaje	Conservar viajes de 1 a 45 minutos	45 minutos es el límite del servicio. Se descartan 164,743 viajes: 163,614 mayores a 45 minutos y 1,129 menores a 1 minuto.
Estaciones pareadas (ej. 271-272)	Conservar el identificador completo como una sola estación	El par corresponde a una estación real del catálogo; no debe dividirse en dos identificadores separados.
Estaciones temporales 1 a 4	Excluirlas sin imputar	Son 722 retiros (0.008 %) y no cuentan con ubicación en el catálogo.
Cruce con el catálogo GBFS	Utilizar el número ce, no station_id	Los identificadores no son equivalentes. El cruce con station_id provocaba velocidades superiores a 30 km/h en 31 % de los viajes.

El filtro de duración conserva el 98.2 % de los viajes. Las estaciones pareadas se mantienen como una sola entidad porque su identificador completo corresponde a una estación del catálogo. En cambio, las estaciones temporales se excluyen de los conteos por estación, ya que no tienen una ubicación que permita incorporarlas correctamente al modelo.

4. Construcción de la tabla para el modelo

Los viajes válidos se agrupan en una tabla con una fila por estación, fecha y hora. De esta manera, la variable objetivo es el número de bicicletas retiradas en cada combinación. La tabla final contiene 2,842,368 filas y permite comparar la demanda de una misma estación en distintos horarios y días.

Las variables explicativas se organizan en tres grupos:

- Calendario: hora, día de la semana y si corresponde a fin de semana.
- Estación: latitud, longitud, capacidad, código postal y alcaldía.
- Contexto reciente: salidas de hace siete días (lag_7d), promedio de los mismos días y horas de las cuatro semanas anteriores (media_4sem) y nivel reciente de la estación (nivel_semana).

4.1 Rezagos y prevención de fuga de información

Los rezagos (lags) resumen el comportamiento pasado de cada estación y permiten que el modelo aproveche información reciente. Para predecir una hora, lag_7d utiliza lo ocurrido una semana antes; media_4sem promedia los cuatro días equivalentes anteriores, y nivel_semana resume el comportamiento de los siete días previos.



Ejemplo de cómo se calculan los rezagos para una estación y una hora determinadas.

La regla es que todos los rezagos miren al menos siete días atrás. Así, para una predicción con una semana de anticipación, el modelo no utiliza información que todavía no estaría disponible. Esto evita la fuga de información (*data leakage*), que consiste en utilizar datos del futuro durante el entrenamiento o la evaluación.

4.2 Entrenamiento, validación y prueba

La división de los datos se realiza por fechas, no de forma aleatoria. Esto permite evaluar el modelo con periodos posteriores a los que utilizó para aprender, como sucedería en una aplicación real.

Conjunto	Periodo	Uso
Entrenamiento	10 de marzo – 29 de junio	Ajustar los parámetros internos del modelo.
Validación	30 de junio – 27 de julio	Elegir configuraciones e hiperparámetros.
Prueba	28 de julio – 31 de agosto	Medir el desempeño final en datos no utilizados para seleccionar el modelo.

Esta partición se utiliza para comparar los seis modelos. Además, se realiza una evaluación mensual adicional con siete periodos de prueba, de marzo a septiembre, en la que cada mes se entrena con la información disponible hasta el mes anterior.

5. Modelos

Se compararon seis alternativas: tres referencias sin aprendizaje y tres modelos de regresión. El objetivo es comprobar si un modelo más complejo logra mejorar una predicción sencilla basada en el comportamiento histórico.

Grupo	Modelo	Cómo predice
Referencia	Promedio histórico	Promedio por estación, hora y tipo de día.
Referencia	Semana pasada	Repite las salidas registradas siete días antes.
Referencia	Media de cuatro semanas	Promedia las cuatro semanas anteriores para el mismo día y hora.
Aprendizaje	Regresión lineal	Calcula una suma ponderada de las variables de entrada.
Aprendizaje	Red neuronal (MLP)	Aprende relaciones no lineales mediante capas de neuronas.
Aprendizaje	XGBoost	Combina árboles de decisión entrenados en secuencia para corregir errores.

Se utiliza un solo modelo global para las 677 estaciones, en lugar de entrenar un modelo independiente para cada una. Esto permite compartir patrones entre estaciones y mantener una sola estructura de predicción. La presentación también reporta que, al retirar código postal y alcaldía de las variables de XGBoost, el RMSE se mantiene en 2.370.

5.1 Arquitectura y configuración

La regresión lineal utiliza variables escaladas. La red neuronal MLP tiene dos capas ocultas de 64 y 32 neuronas, con activación ReLU. Su optimizador es Adam, con tasa de aprendizaje de 0.001, función de pérdida de error cuadrático y lotes de 2,048 filas. Se entrenó con una muestra de 1.5 millones de filas, hasta 15 épocas y con *early stopping* de paciencia de tres épocas.

XGBoost utiliza árboles de decisión con objetivo Poisson (count:poisson), adecuado para modelar conteos no negativos. Los hiperparámetros se eligieron mediante una búsqueda aleatoria de 12 combinaciones entre 864 posibles. La configuración seleccionada fue:

Hiperparámetro	Valor elegido
learning_rate	0.1
max_depth	8
subsample	1.0
colsample_bytree	0.8
min_child_weight	20
objective	count:poisson
Número de árboles	374 (máximo de 1,000)

6. Resultados

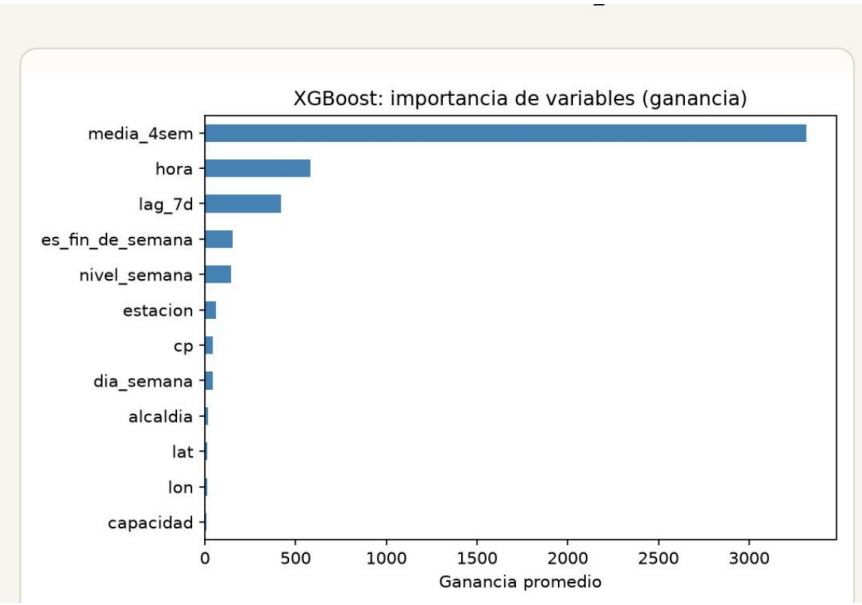
XGBoost obtuvo el mejor resultado en el conjunto de prueba, con un RMSE de 2.370, frente a 2.559 del promedio histórico. Esto representa una mejora de 7.4 % en la métrica principal. También obtuvo el menor MAE y un sesgo cercano a cero.

Modelo	RMSE	MAE	Sesgo	Mejora de RMSE
XGBoost (Poisson)	2.370	1.383	+0.060	7.4 %
Red neuronal (MLP)	2.419	1.396	+0.040	5.5 %
Regresión lineal	2.453	1.466	+0.043	4.2 %
Media de 4 semanas	2.494	1.449	−0.028	2.6 %
Promedio histórico	2.559	1.448	+0.171	Referencia
Semana pasada	3.055	1.747	−0.019	−19.4 %

La prueba corresponde al periodo del 28 de julio al 31 de agosto de 2026 y contiene 567,072 filas. El RMSE penaliza con mayor fuerza los errores grandes, mientras que el MAE resume el error absoluto promedio. En este caso, el MAE de XGBoost es de 1.383 salidas por estación y hora. El sesgo positivo (+0.060) indica una ligera tendencia a sobreestimar, aunque es menor que la del promedio histórico (+0.171).

6.1 Variables más importantes y sobreajuste

La variable más importante para XGBoost es la media de las últimas cuatro semanas (media_4sem), seguida de la hora y las salidas de hace siete días (lag_7d). Esto indica que el comportamiento reciente de cada estación aporta más información que su ubicación por sí sola.

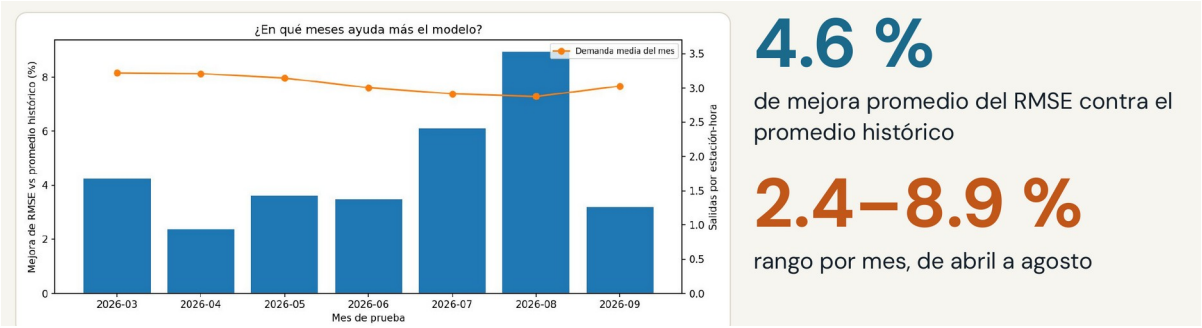


Importancia de variables en XGBoost, medida por ganancia.

Los errores de entrenamiento y prueba son similares. XGBoost registra un RMSE de 2.385 en entrenamiento y 2.370 en prueba; MLP, 2.486 y 2.419; y regresión lineal, 2.645 y 2.453. La presentación interpreta esta cercanía como evidencia de que no se observa un sobreajuste marcado.

7. Validación en distintos meses y experimentos

Además de la prueba principal, se realizó una evaluación mensual de marzo a septiembre de 2026. En cada periodo, el entrenamiento utiliza toda la información anterior. XGBoost obtuvo el menor RMSE frente al promedio histórico en los siete meses, con una mejora promedio de 4.6 %. La mejora mensual reportada va de 2.4 % a 8.9 % entre abril y agosto; septiembre, que no había sido utilizado en experimentos previos, también mejora 3.2 %.



Mejora mensual del RMSE de XGBoost respecto al promedio histórico.

La presentación señala como limitación que los hiperparámetros se eligieron con datos de junio y julio. Por ello, la validación mensual debe interpretarse junto con esta consideración metodológica.

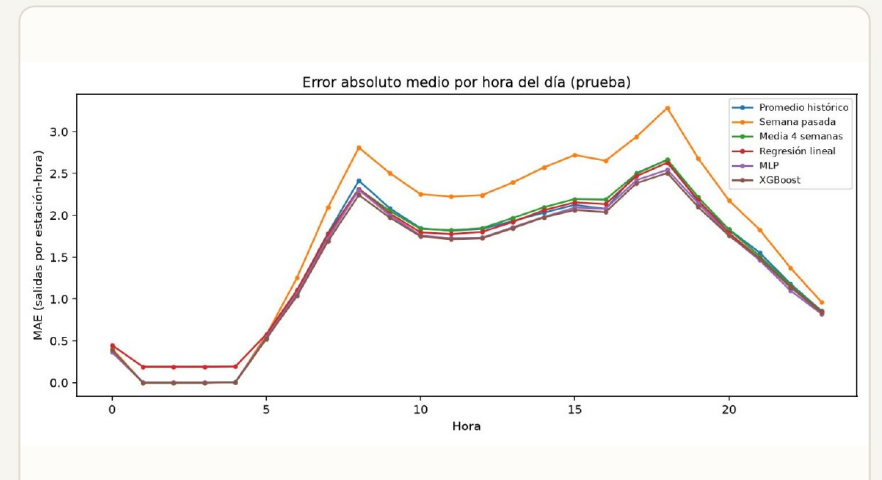
7.1 Experimentos adicionales

Experimento	Resultado	Interpretación
Calendario escolar y clima	RMSE 2.393 (v1: 2.370)	No mejora el RMSE; los rezagos ya reflejan parte de las vacaciones y el clima proviene de un solo punto.
Un año de datos	XGBoost: 2.395; MLP: 2.460; lineal: 2.450	Con la misma prueba, los modelos empeoran ligeramente, salvo la regresión lineal, que mejora 0.003.
Predicción a un día	RMSE 2.354 (v1: 2.370)	Saber lo ocurrido el día anterior mejora poco y puede servir para el restock diario.
Tres ventanas de prueba	Gana en las tres: 2.3 % a 7.4 %	La mejora no depende de una sola ventana temporal.

El experimento con un año utiliza datos de septiembre de 2025 a agosto de 2026 y mantiene el mismo periodo de prueba (28 de julio a 31 de agosto de 2026). El RMSE de XGBoost pasa de 2.370 con seis meses a 2.395 con un año; el promedio histórico también empeora, de 2.559 a 2.605. Esto sugiere que añadir historia más antigua no necesariamente mejora la predicción, porque puede representar otra temporada y el modelo depende del comportamiento reciente.

8. Análisis de errores

El error no se distribuye de manera uniforme. En las horas pico de las 8 y las 18 horas se concentran más viajes y también aumentan los errores. Durante la noche, entre las 19 y las 23 horas, el modelo tiende a predecir de más.



Error absoluto medio por hora del día en el conjunto de prueba.

Por estación, la 271-272 presenta un RMSE de 13.8 y es la de mayor volumen. Por alcaldía, Cuauhtémoc registra el mayor error, con RMSE de 2.93. En junio, todos los modelos sobreestiman las salidas. La presentación plantea como hipótesis la coincidencia con el Mundial y las lluvias, pero aclara que esta explicación no está comprobada.

9. Discusión y conclusiones

Los resultados muestran que XGBoost puede mejorar la predicción frente al promedio histórico, aunque la diferencia es moderada. Una razón importante es que el promedio histórico ya captura patrones por estación, hora y tipo de día. XGBoost aprovecha además el comportamiento reciente de cada estación, sobre todo mediante la media de las últimas cuatro semanas.

Los experimentos también muestran que agregar más variables o más meses de información no garantiza una mejora. El calendario escolar y el clima no redujeron el RMSE; utilizar un año de datos empeoró el resultado de XGBoost en la prueba principal, mientras que predecir a un día mejoró el RMSE ligeramente. La demanda por estación y hora conserva una parte importante de variabilidad que no está explicada por las variables disponibles.

De aquí se desprenden tres conclusiones:

- XGBoost supera al promedio histórico en los siete meses evaluados, con una mejora promedio del RMSE de 4.6 % en la evaluación mensual.
- La información reciente es la característica más importante: la media de las cuatro semanas anteriores tiene mayor peso que las variables geográficas.
- Más variables y más historia no produjeron mejoras relevantes. La variabilidad de la demanda en cada hora sigue siendo una limitación importante.

10. Limitaciones y próximos pasos

El modelo predice las salidas observadas, pero estas no siempre representan toda la demanda. Si una estación está vacía, no se registran salidas aunque haya personas que quieran tomar una bicicleta. Por ello, el modelo puede interpretar como demanda baja una situación en la que en realidad faltó oferta.

También existe una variabilidad considerable: en promedio se registran alrededor de tres salidas por estación y hora, por lo que unas cuantas bicicletas pueden cambiar de manera importante el error. Además, el modelo no incorpora eventos externos como partidos, marchas o cierres de calles. La presentación identifica otra limitación en la selección de hiperparámetros, que se realizó utilizando datos de junio y julio.

Los siguientes pasos propuestos son:

- Revisar la demanda diaria de junio para entender por qué todos los modelos sobreestimaron las salidas.
- Agregar información de eventos y cercanía a estaciones de Metro y Metrobús.
- Probar modelos por tipo de estación, por ejemplo, residencial, de oficinas o turística.
- Predecir también los arribos para estimar el inventario de cada estación y planear el rebalanceo completo.

Fuentes

- Presentación del proyecto: “Predicción de demanda de Ecobici en la Ciudad de México”, segunda entrega, 4 de noviembre de 2026.
- Portal de datos abiertos de Ecobici CDMX: https://ecobici.cdmx.gob.mx/es/datos-abiertos
- Feed GBFS de Ecobici: https://gbfs.mex.lyftbikes.com
- Repositorio del proyecto: https://github.com/taniahdzl/ecobici-demand-forecast